Compiladores - Projecto

Mili-Pascal

31 Maio 2014

Grupo: Miguéis;

João Miguel Borges Subtil Nº 2012151975
Pedro Miguel Quitério Lourenço Nº 2012143635

Compiladores - Projecto 1
1 Introdução 3
2 Análise Lexical 4
2.1 Tokens 4
2.2 Comentários 5
2.3 Tratamento de Erros 6
3 Analisador Sintáctico 7
3.1 Gramática 8
3.1.1 Gramática inicial 8
3.1.2 Gramática na forma BNF 9
3.2 Tratamento de erros sintáticos 11
3.3 Árvore de sintaxe Abstracta 11
3.3 Análise Semântica 12

1 Introdução

No presente trabalho pretende-se desenvolver um compilador para a linguagem mili-pascal, um pequeno subconjunto da Linguagem Pascal.
O projecto foi estruturado em 4 fases, a primeira consistia na análise lexical para qual foi usada a ferramenta *Lex,* a segunda consistia na análise sintática recorrendo á ferramenta *yacc,* a terceira consistia na construção de tabelas e detecção de erros semânticos e, por fim a última fase consistia na geração de código em LLVM.
O seguinte esquema ilustra as fases de compilação.

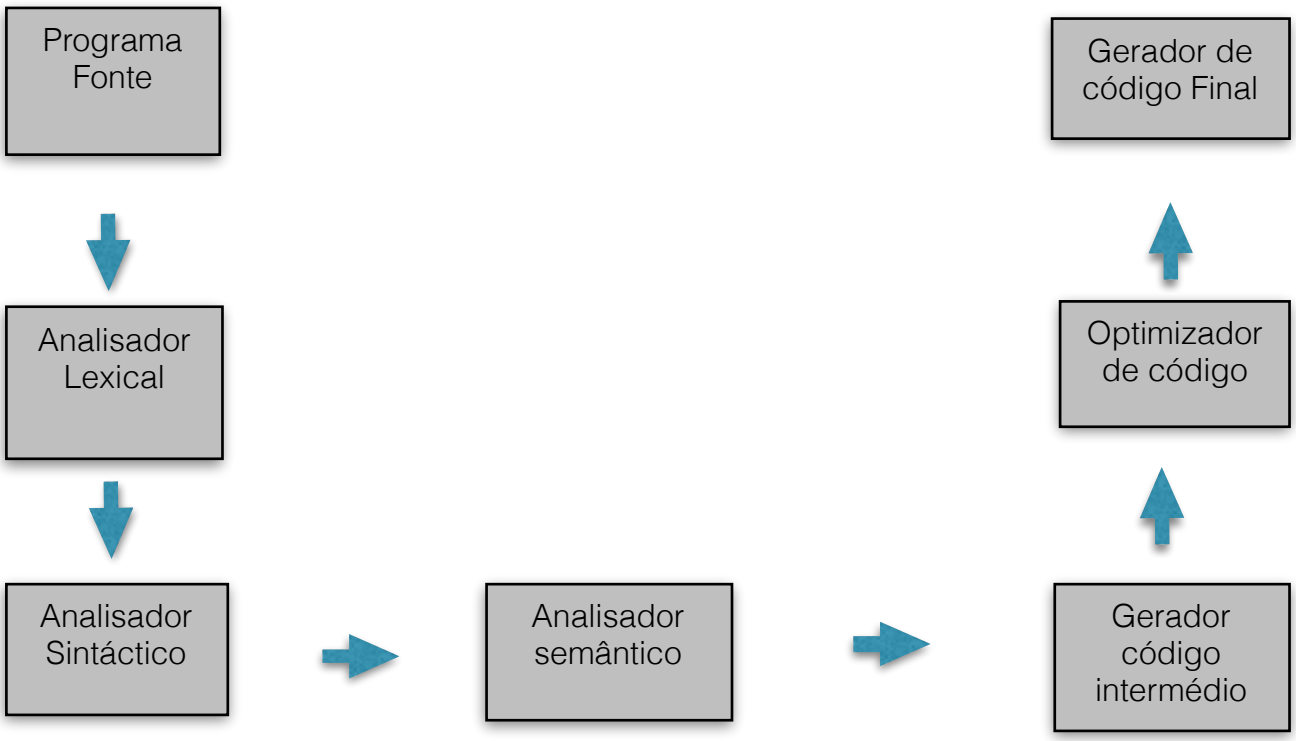

2 Análise Lexical

A análise lexical consiste em analisar o input dado e produzir uma cadeia de símbolos que podem ser manipulados pelo *parser.*
No nosso analisador os comentários são tratados com recurso a uma macro, assim sempre que o lex lê "(* …*)" ou "{ …}" ou uma mistura entre os dois o analisador ignora o que estiver dentro desse comentário.
Sempre que é detectado um caracter ou uma sequência de caracteres que não constituam um *token* é gerado um erro lexical, sendo impressa uma mensagem de erro contendo o tipo, visto que podem existir vários tipos de erros diferentes, com o número da linha e coluna onde ocorreu.

2.1 Tokens

De seguida apresentamos a lista de *tokens* aceites pela linguagem sendo que não estão representadas as palavras reservadas por questões de comodidade. Foram também definidos novos *tokens* para facilitar depois a construção da AST numa fase posterior.

- **ID:** Sequências alfanuméricas começadas por uma letra e seguidas por uma combinação de letras e/ou números *" [a-z][a-z0-9]* "*
- **Intlit:** sequências de dígitos decimais. *" [0-9]+"*
- **Reallit:** Sequências de dígitos decimais interrompidas por um único ponto e opcionalmente seguidas de um expoente, *ou* sequências de dígitos decimais seguidas de um expoente. O expoente consiste na letra "e", opcionalmente seguida de um sinal de + ou de - , seguida de uma sequência de dígitos decimais. *" {num}("."{num})?(e[-+]?{num})? "*
- **String**: Sequências de caracteres (excluindo mudanças de linha) iniciadas por uma aspa simples (') e terminadas pela primeira ocorrência de uma aspa simples que não seja seguida imediatamente por outra aspa simples. *""'([^\n']|'')*'""*
- **Assign:** ":="
- **Begin:** "begin"
- **Colon:** ":"
- **Comma:** ","
- **Do:** "do"
- **Dot:** "."
- **Else:** "else"
- **End:** "end"
- **Forward:** "forward"

- **Function:** “function”
- **If:** “if”
- **Lbrac:** “(“
- **Not:** “not”
- **Output:**”output”
- **Paramstr:** “paramstr”
- **Program:** “program”
- **Rbrac:** “)”
- **Repeat:** “repeat”
- **Semic:** “;”
- **Then:** “then”
- **Until:** “until”
- **Val:** ”val”
- Var: “var”
- While: “while”
- Writeln: “writeln”
- Op1: ”and “ | ”or”
- Op2: "<" | ">" | "=" | "<>" | "<=" | ">="
- Op3: "+" | “-"
- Op4: "*" | "/" | "mod" | "div"
- RESERVED: palavras reservadas e identificadores requeridos do Pascal standard não usados.

Foram criados novos tokens com base na separação dos tokens OP1, OP2 e OP4 para resolver problemas de ambiguidade, as transformação são apresentadas em baixo

- A op1 foi partida em AND e OR
- Em op2 “<>” passou a NEQ, “<=“ passou a LEQ, “>=“ passou a GEQ
- Na op4 “mod” e “div” passaram a MOD e DIV respectivamente
- BEGIN passou BEG

2.2 Comentários

Para identificar correctamente os comentários recorremos á macro TESTECOMENT, quando é detectado o início de um comentário tudo é ignorado até o mesmo ser terminado correctamente com “*)” ou “}”, esta macro também trata os casos de comentário multi-linha.

Caso seja detectado um <<EOF>> sem o comentário ter sido terminado correctamente, é exibida uma mensagem de erro com a linha e a coluna em que começa o dito comentário.

2.3 Tratamento de Erros

Tal como já foi referido anteriormente sempre que o analisador detecta um erro (quer seja por um comentário/string não terminado(a)) é impressa uma mensagem de erro que indica a linha e a coluna em que o dito erro ocorreu.
Quando é detectado um caracter ilegal é impressa a mensagem de “ilegal caracter” com a respectiva linha e coluna, o programa continua até chegar ao fim.
Após todo o conteúdo ter sido analisado o programa termina e imprime as mensagens correspondentes aos erros detectados, se existirem.

3 Analisador Sintáctico

O analisador sintáctico foi implementado com recurso á ferramenta *yacc*, a ideia é o *lex* reconhecer os tokens e posteriormente enviá-los ao yacc que irá verificar se estes pertencem á linguagem.

Sempre que o *lex* identifica um token envia-o ao *yacc*, contudo este token pode ser recebido como *yytext* numa estrutura *union* criada especialmente para facilitar a manipulação e armazenamento de dados , ou pode ser enviado como *token* que também está definido no início do ficheiro mpaparser.y.

```
%union{
    char* str;
    int u_line,u_col;
    struct _node * node;
}
```

Esta estrutura contém um campo(char*) para armazenar Id´s, Intlit´s, Reallits e Strings, contém também um campo para a linha e a coluna (embora não estejam a ser usados) e por fim uma estrutura (node) que depois irá ser utilizada para a construção da AST.

Foi necessário também definir algumas variáveis externas como o *yytext*, linha e coluna para partilhar valores entre ambos os programas.

```
extern int line;
extern unsigned long col;
extern char* yytext;
```

3.1 Gramática

A gramática é a maneira formal de especificar a sintaxe de uma linguagem. Para o projecto foi nos fornecida a gramática na forma EBNF, contudo esta teve de ser transformada para BNF para remover as ambiguidades.

3.1.1 Gramática inicial

Prog → ProgHeading SEMIC ProgBlock DOT
ProgHeading → PROGRAM ID LBRAC OUTPUT RBRAC
ProgBlock → VarPart FuncPart StatPart
VarPart → [VAR VarDeclaration SEMIC { VarDeclaration SEMIC }] VarDeclaration
→ IDList COLON ID
IDList → ID { COMMA ID }
FuncPart → { FuncDeclaration SEMIC }
FuncDeclaration → FuncHeading SEMIC FORWARD
FuncDeclaration → FuncIdent SEMIC FuncBlock
FuncDeclaration → FuncHeading SEMIC FuncBlock
FuncHeading → FUNCTION ID [FormalParamList] COLON ID
FuncIdent → FUNCTION ID
FormalParamList → LBRAC FormalParams { SEMIC FormalParams } RBRAC
FormalParams → [VAR] IDList COLON ID
FuncBlock → VarPart StatPart
StatPart → CompStat
CompStat → BEGIN StatList END
StatList → Stat { SEMIC Stat }
Stat → CompStat
Stat → IF Expr THEN Stat [ELSE Stat]
Stat → WHILE Expr DO Stat
Stat → REPEAT StatList UNTIL Expr
Stat → VAL LBRAC PARAMSTR LBRAC Expr RBRAC COMMA ID RBRAC
Stat → [ID ASSIGN Expr]
Stat → WRITELN [WritelnPList]
WritelnPList → LBRAC (Expr | STRING) { COMMA (Expr | STRING) } RBRAC
Expr → Expr (OP1 | OP2 | OP3 | OP4) Expr
Expr → (OP3 | NOT) Expr
Expr → LBRAC Expr RBRAC
Expr → INTLIT | REALLIT

Expr → ID [ParamList]
ParamList → LBRAC Expr {COMMA Expr} RBRAC

3.1.2 Gramática na forma BNF

Para remover as ambiguidades tivemos de efectuar diversas alterações, algumas delas foram:

- Criação de estados adicionais para regras que implicam repetição de tokens
- Estabelecimento de prioridades entre operadores
- Definição de regras de associação

```
%left OR AND NO

%nonassoc THEN
%nonassoc ELSE
%nonassoc '<' '>' '='
%nonassoc LEQ NEQ GEQ
```

A gramática resultante das alterações acima descritas é a seguinte:

```
Program              : ProgHeading  ';'  ProgBlock  '.'
ProgHeading          : PROGRAM ID '(' OUTPUT ')'
ProgBlock            : VarPart FuncPart StatPart
VarPart              : VAR VarDeclaration ';' VarPart2
                     |
VarPart2             : VarDeclaration ';' VarPart2
                     |
VarDeclaration       : IDList ':' ID
IDList               : ID IDList2
IDList2              : ',' ID IDList2
                     |
FuncPart             : FuncDeclaration ';' FuncPart
                     |
FuncPart             : FuncDeclaration ';' FuncPart
                     | FuncIdent ';' FuncBlock
                     | FuncHeading ';' FuncBlock
FuncHeading          : FUNCTION ID ':' ID
                     | FUNCTION ID FormalParamList ':' ID
FuncIdent            : FUNCTION ID
FormalParamList      : '(' FormalParams FormalParamListaux ')'
FormalParamListaux   : ';' FormalParams FormalParamListaux
FormalParams         : IDList ':' ID
                     | VAR IDList ':' ID
FuncBlock            : VarPart StatPart
```

```
StatPart            : CompStat
CompStat            : BEG StatList END
StatList            : Stat Stat2
Stat2               : ';' Stat Stat2
                    |
Stat                : CompStat
                    | IF Expr THEN Stat
                    | IF Expr THEN Stat ELSE Stat
                    | WHILE Expr DO Stat
                    | REPEAT StatList UNTIL Expr
                    | VAL '(' PARAMSTR '(' Expr ')' ',' ID ')'
                    | optStat2
                    | WRITELN
                    | WRITELN WritelnPList
optStat2            : ID ASSIGN Expr
                    |
WritelnPList        : '(' optWritelnPList WritelnPList2 ‘)'
optWritelnPList     : Expr
                    | STRING
WritelnPList2       : ',' optWritelnPList WritelnPList2
                    |
Expr                : SimpleExpression
                    | SimpleExpression '=' SimpleExpression
                    | SimpleExpression '>' SimpleExpression
                    | SimpleExpression '<' SimpleExpression
                    | SimpleExpression LEQ SimpleExpression
                    | SimpleExpression NEQ SimpleExpression
                    | SimpleExpression GEQ SimpleExpression
SimpleExpression    : '+' Term
                    | '-' Term
                    | Term
                    | SimpleExpression '+' Term
                    | SimpleExpression '-' Term
                    | SimpleExpression OR Term
Term                : Term AND Factor
                    | Term MOD Factor
                    | Term DIV Factor
                    | Term '*' Factor
                    | Term '/' Factor
                    | Factor
Factor              : NOT Factor
                    | '(' Expr ')'
                    | INTLIT
                    | REALLIT
                    | ID ParamList
                    | ID
ParamList           : '(' Expr repParamList ‘)'
repParamList        : ',' Expr repParamList
                    |
```

3.2 Tratamento de erros sintáticos

O tratamento de erros sintáticos é feito recorrendo á função *yyerror* que imprime a linha, coluna e o erro detectado.

```
void yyerror (char *s) {
    printf ("Line %d, col %d: %s: %s\n", line, (int)(col)-(int)strlen(yytext), s, yytext);
}
```

3.3 Árvore de sintaxe Abstracta

Para a estrutura da árvore decidimos criar um nó genérico que contém a informação necessária para tornar ao seu acesso mais simples tanto na sua criação como em acessos futuros.

```
typedef struct _node {

    char *id;
    struct _node *brother;
    struct _node *son;
    char * type;
    char * value;
    int line;
    int col;

}Node;
```

As funções seguintes são responsáveis pela criação da árvore de sintaxe abstracta, a função make_node cria o nó e devolve-o para ser ligado a outros nós, a função addBrother insere um nó como irmão de outro, o addChild adiciona um nó como filho, a função printAll imprime tudo recursivamente e as duas funções checkstatlist verificam como se deve adicionar um novo nó “Statlist”.

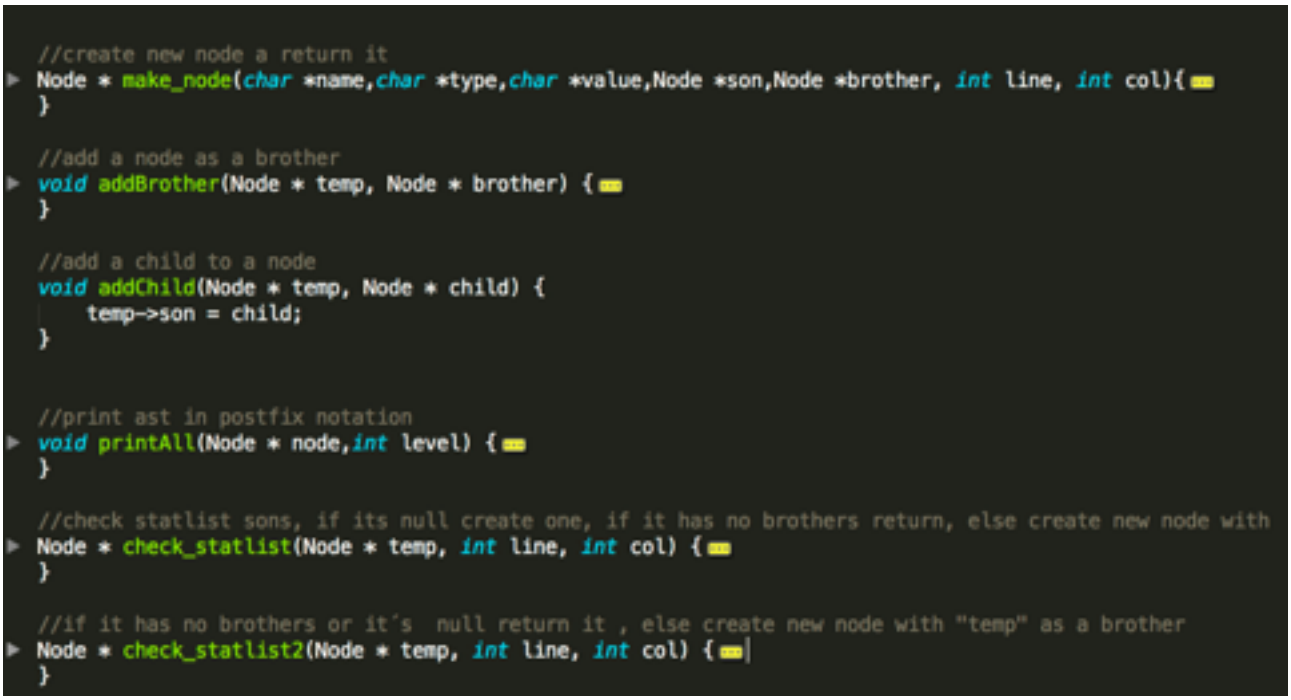

3.3 Análise Semântica